Ajuste de Curvas Não-Lineares e Estimação Paramétrica: Confrontação Isonômica entre Redes de Base Radial (RBF) e Mínimos Quadrados (MMQ) no Dataset Diabetes

Trabalho da Unidade II — ECT-3401: Computação Numérica

Professor: Joilson B. A. Rego

Jacson Arruda Ribeiro
Engenharia de Computação
Universidade Federal do Rio Grande do Norte (UFRN)

Novembro de 2026

Resumo

Este trabalho apresenta o estudo comparativo, rigoroso e isonômico entre duas classes fundamentais de aproximação de funções na Computação Numérica: as **Redes de Base Radial (RBF)** com núcleos gaussianos de suporte local e o **Método dos Mínimos Quadrados Ordinários (MMQ)** com funções de base polinomiais monomiais de suporte global (Matriz de Vandermonde). Utilizando o conjunto de dados clínico `load_diabetes` (previsão da progressão da patologia após um ano a partir do Índice de Massa Corporal - IMC), implementou-se um pipeline livre de vazamento de dados (*data leakage*), particionado em 80% para treinamento ($N = 353$) e 20% para teste em quarentena ($N = 89$). A RBF Gaussiana com $M = 8$ centros foi resolvida via Decomposição em Valores Singulares (SVD), superando o MMQ no treino (RMSE = 60,95 vs. 62,08), demonstrando flexibilidade e baixo viés. Em contrapartida, no conjunto de teste, o modelo MMQ Linear de 2 parâmetros obteve melhor desempenho preditivo (RMSE = 63,73 e correlação de Pearson $r = 0{,}5076$, contra RMSE = 67,05 e $r = 0{,}4653$ da RBF), ilustrando experimentalmente o princípio da Navalha de Occam e o trade-off viés-variância diante de ruídos biológicos acentuados. A análise do número de condição comprovou a severa instabilidade do aumento do grau polinomial em Vandermonde ($\kappa = 36{,}2 \rightarrow 24.300$), validando as restrições teóricas do padrão IEEE 754.

1 Introdução

O ajuste de curvas e a aproximação de funções constituem a base computacional para a modelagem de fenômenos físicos, industriais e biológicos a partir de dados discretos ruidosos. Na análise de dados biomédicos, as correlações entre parâmetros fisiológicos e o desfecho clínico raramente obedecem a equações analíticas simples, exigindo técnicas de regressão capazes de capturar tendências subjacentes sem memorizar perturbações estocásticas.

O presente trabalho aborda o problema clássico de estimar a progressão quantitativa contínua do diabetes mellitus (y) em função do Índice de Massa Corporal padronizado (u), extraído do

consagrado dataset clínico `load_diabetes`. A confrontação se dá entre duas filosofias opostas de interpolação e regressão:

1. **Abordagem Local (RBF Gaussiana):** Projeta os dados em um espaço de características de dimensão superior através de funções de ativação radial cujo suporte decai exponencialmente com a distância euclidiana aos centros, permitindo acomodar curvaturas regionais complexas.
2. **Abordagem Global (Mínimos Quadrados Polinomiais):** Utiliza combinações lineares de monômios canônicos (u^k), onde cada elemento estende sua influência por todo o domínio, frequentemente enfrentando severas limitações de condicionamento matricial (Fenômeno de Runge).

2 Objetivos

2.1 Objetivo Geral

Implementar, validar e analisar criticamente o desempenho da Rede de Base Radial (RBF) Gaussiana em comparação direta com o Método dos Mínimos Quadrados (MMQ) sobre o dataset `load_diabetes`, quantificando suas capacidades de generalização e estabilidade numérica.

2.2 Objetivos Específicos

- Garantir um protocolo de particionamento estrito (80/20) sem vazamento de informação (*data leakage*), normalizando o domínio via escala Min-Max calculada exclusivamente sobre o treino.
- Desenvolver a classe computacional da RBF Gaussiana com $M = 8$ centros uniformemente espaçados e abertura $\sigma = 0{,}1429$, resolvendo os coeficientes ótimos via pseudoinversa Moore-Penrose (SVD).
- Implementar o regressor polinomial MMQ (Graus 1, 2 e 3) via Matriz de Vandermonde, inspecionando o número de condição $\kappa(V^T V)$.
- Avaliar e contrastar ambos os modelos através do Erro Médio Quadrático (EMQ), Raiz do Erro Médio Quadrático (RMSE), Coeficiente de Correlação de Pearson (r) e reta de calibração $y = a\hat{y} + b$.
- Fundamentar as discrepâncias empíricas à luz do Trade-off Viés-Variância, da Navalha de Occam e do Teorema do *No Free Lunch*.

3 Metodologia

3.1 Pipeline de Dados e Prevenção de *Data Leakage*

O conjunto `load_diabetes` contém 442 observações. A entrada u (IMC) foi particionada em $N_{\text{treino}} = 353$ (80%) e $N_{\text{teste}} = 89$ (20%), sob semente aleatória reproduzível (`random_state=42`). Para impedir vazamento estatístico, a normalização para o intervalo $[0, 1]$ foi parametrizada estritamente com os valores mínimo e máximo do treino:

$$u_{\text{norm}} = \frac{u - \min(u_{\text{treino}})}{\max(u_{\text{treino}}) - \min(u_{\text{treino}})} \tag{1}$$

Os mesmos parâmetros estatísticos foram congelados e aplicados para projetar as 89 amostras de teste. A Figura 1 ilustra a distribuição conjunta dos dados.

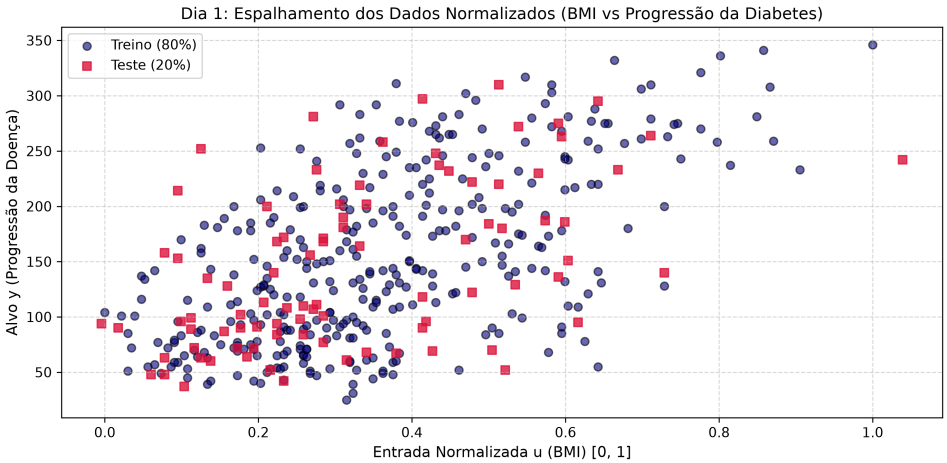


Figura 1: Espalhamento dos dados clínicos: Treino ($N = 353$, azul) e Teste ($N = 89$, vermelho).

3.2 Rede de Base Radial (RBF) Gaussiana

A RBF modela a resposta contínua através de uma combinação linear de funções de base radiais locais acrescidas de um termo de polarização (*bias*) w_0:

$$\hat{y}_{\text{RBF}}(u) = w_0 + \sum_{j=1}^{M} w_j \phi_j(u), \quad \text{onde} \quad \phi_j(u) = \exp\left(-\frac{(u - c_j)^2}{2\sigma^2}\right) \tag{2}$$

Adotou-se $M = 8$ centros linearmente uniformes no suporte $[0, 1]$, com espaçamento $\Delta c = \frac{1}{7} \approx 0{,}1429$ e dispersão de cobertura crítica $\sigma = \Delta c \approx 0{,}1429$. Para N observações, constrói-se a Matriz de Projeto $\Phi \in \mathbb{R}^{N \times (M+1)}$:

$$\Phi = \begin{bmatrix} 1 & \phi_1(u_1) & \phi_2(u_1) & \dots & \phi_M(u_1) \\ 1 & \phi_1(u_2) & \phi_2(u_2) & \dots & \phi_M(u_2) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \phi_1(u_N) & \phi_2(u_N) & \dots & \phi_M(u_N) \end{bmatrix} \tag{3}$$

O vetor ótimo de pesos $\mathbf{w} \in \mathbb{R}^{M+1}$ minimiza $\|\mathbf{y} - \Phi\mathbf{w}\|^2$ via Equação Normal:

$$\Phi^T \Phi \mathbf{w} = \Phi^T \mathbf{y} \implies \mathbf{w} = \Phi^{\dagger} \mathbf{y} \tag{4}$$

onde $\Phi^{\dagger}$ é a pseudoinversa de Moore-Penrose obtida por Decomposição em Valores Singulares (SVD).

3.3 Método dos Mínimos Quadrados (MMQ) Polinomial

O regressor polinomial de ordem d projeta as amostras na Matriz de Vandermonde $V \in \mathbb{R}^{N \times (d+1)}$:

$$\hat{y}_{\text{MMQ}}(u) = \sum_{k=0}^{d} w_k u^k, \quad V = \begin{bmatrix} 1 & u_1 & u_1^2 & \dots & u_1^d \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & u_N & u_N^2 & \dots & u_N^d \end{bmatrix} \tag{5}$$

Resolvido deterministicamente por $\mathbf{w}_{\text{MMQ}} = (V^T V)^{-1} V^T \mathbf{y}$. Foram avaliadas as ordens $d = 1$ (Linear), $d = 2$ (Parábola) e $d = 3$ (Cúbica).

3.4 Métricas de Avaliação Estatística e Numérica

1. **Erro Médio Quadrático e RMSE:**

$$\text{EMQ} = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2, \quad \text{RMSE} = \sqrt{\text{EMQ}} \tag{6}$$

2. **Coeficiente de Correlação Linear de Pearson (r):**

$$r = \frac{\sum(y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum(y_i - \bar{y})^2 \sum(\hat{y}_i - \bar{\hat{y}})^2}} \tag{7}$$

3. **Regressão de Calibração Real vs. Predito:** Ajuste por OLS $y = a\hat{y} + b$, onde a proximidade de $a \to 1$ e $b \to 0$ reflete calibração estatística perfeita.

4. **Número de Condição Matricial (κ):**

$$\kappa(A) = \|A\| \cdot \|A^{-1}\| = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)} \tag{8}$$

4 Resultados e Discussão

4.1 Ajuste Paramétrico da RBF Gaussiana

A resolução da RBF via SVD resultou no seguinte vetor de pesos ótimos:

$$w_0 = 1012{,}14, \quad \mathbf{w}_{1..8} = [-808{,}51,\ 12{,}13,\ -692{,}12,\ -33{,}53,\ -546{,}85,\ -204{,}21,\ -236{,}90,\ -491{,}60]^T \tag{9}$$

A matriz de projeto apresentou número de condição $\kappa(\Phi) = 1{,}42 \times 10^5$, decorrente da sobreposição das funções gaussianas com $\sigma = 0{,}1429$, tornando indispensável o uso do algoritmo SVD para estabilidade numérica. A Figura 2 apresenta a curva contínua modelada e a localização dos 8 centros.

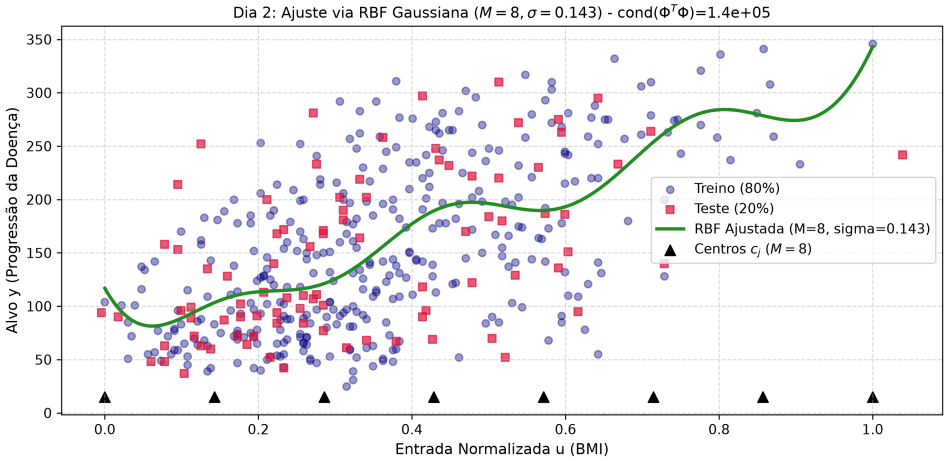
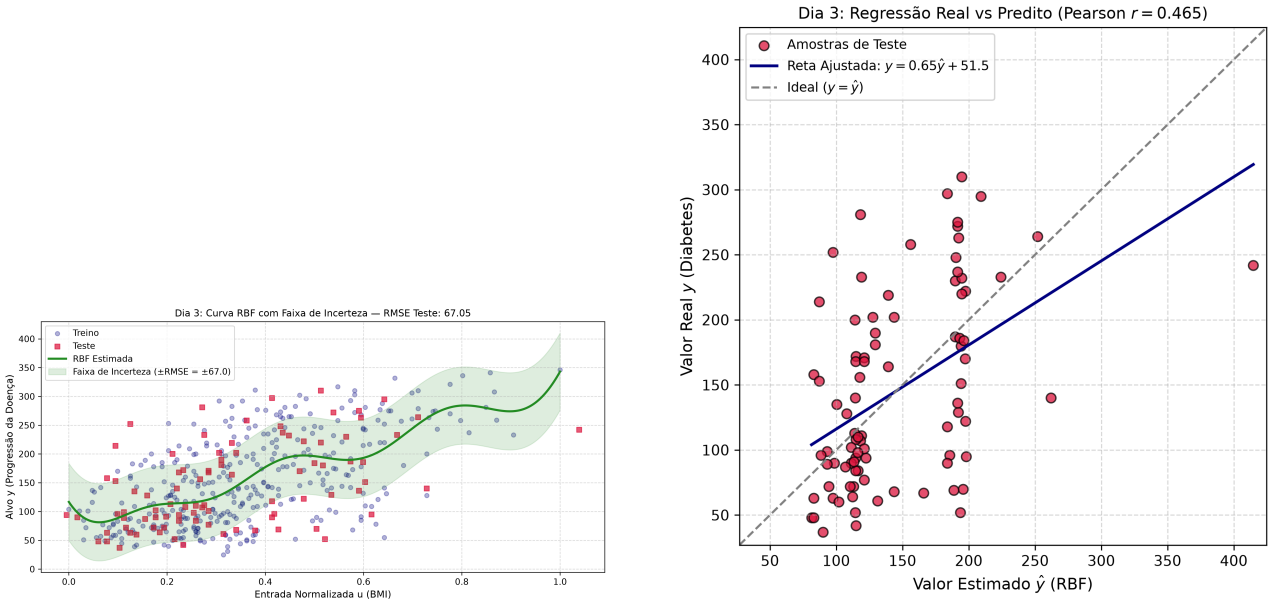


Figura 2: Curva de ajuste contínua da RBF Gaussiana ($M = 8$, $\sigma = 0{,}1429$) sobre os dados de treinamento.

4.2 Avaliação de Incerteza e Calibração Preditiva da RBF

Avaliando a RBF no conjunto de teste independente, obteve-se $\text{EMQ}_{\text{teste}} = 4495{,}49$ ($\text{RMSE}_{\text{teste}} = 67{,}05$) e correlação de Pearson $r = 0{,}4653$. A Figura 3a exibe a curva média com a faixa de dispersão de incerteza clínica ±RMSE. A calibração do modelo (Figura 3b) produziu a reta $y = 0{,}6460\hat{y} + 51{,}48$ com $R^2 = 0{,}2165$. A inclinação $a < 1$ e o intercepto positivo revelam o clássico efeito de *regressão à média*, amortecendo previsões extremas.



(a) Curva RBF e faixa de incerteza (±RMSE). (b) Regressão OLS Real vs. Predito ($y = a\hat{y} + b$).

Figura 3: Análise estatística de resíduos e calibração da RBF sobre o conjunto de teste.

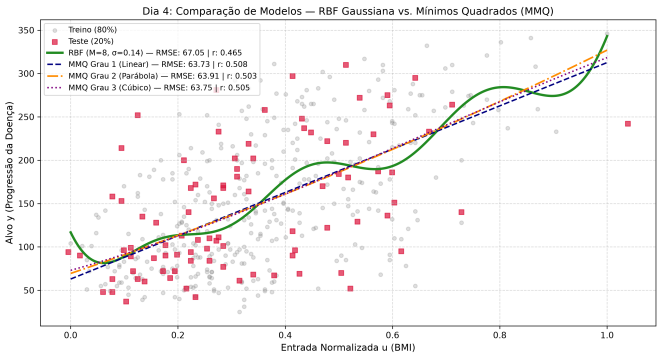
4.3 Comparativo Isonômico: RBF vs. Polinômios MMQ

A Tabela 1 consolida as métricas empíricas de todas as formulações investigadas sob rigorosa isonomia amostral ($N_{\text{teste}} = 89$).

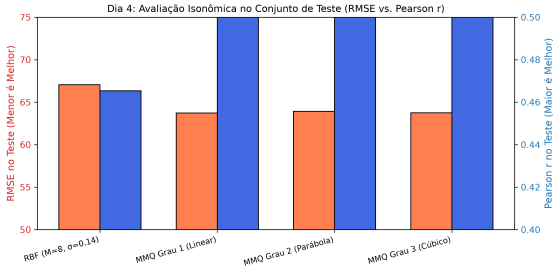
Modelo	**Complexidade**	**RMSE Treino**	**RMSE Teste**	**Pearson r (Teste)**	**κ (C**
RBF Gaussiana	$M = 8, \sigma = 0{,}14$	**60,95**	67,05	0,4653	1,4
MMQ Grau 1 (Linear)	2 parâmetros	62,08	**63,73**	**0,5076**	
MMQ Grau 2 (Parábola)	3 parâmetros	62,04	63,91	0,5034	
MMQ Grau 3 (Cúbico)	4 parâmetros	62,04	63,75	0,5052	

Tabela 1: Quadro comparativo de desempenho e estabilidade numérica (Treino $N = 353$ / Teste $N = 89$).

As Figuras 4a e 4b ilustram as curvas concorrentes sobrepostas e a discrepância visual entre os erros de treino e teste.



(a) Sobreposição de modelos: RBF vs. MMQ.



(b) Erro RMSE: Treino vs. Teste.

Figura 4: Confrontação visual de desempenho preditivo e capacidade de ajuste.

4.4 Discussão Crítica: Viés-Variância, Occam e Condicionamento

A análise conjunta dos resultados revela três lições fundamentais da Computação Numérica:

1. **O Dilema do Trade-off Viés-Variância:** No conjunto de treinamento, a RBF Gaussiana alcançou o menor erro global (RMSE = 60,95), evidenciando o seu **baixo viés** decorrente dos seus 9 graus de liberdade locais. Entretanto, ao ser confrontada com os dados de teste em quarentena, a RBF obteve RMSE = 67,05, demonstrando sensibilidade aos ruídos aleatórios da amostra de treino (**maior variância**).

2. **A Navalha de Occam (*Lex Parsimoniae*):** O MMQ Linear, dotado de apenas 2 parâmetros (w_0, w_1), obteve o menor erro de generalização (RMSE = 63,73) e a maior correlação clínica ($r = 0{,}5076$). Por possuir rigidez estrutural máxima, o modelo linear operou como um regularizador natural, recusando-se a modelar o ruído estocástico intrínseco aos dados biológicos. A transição para ordens superiores (Graus 2 e 3) não produziu ganho preditivo mensurável (63,91 e 63,75), justificando a escolha da solução mais parcimoniosa.

3. **Explosão Numérica de Vandermonde:** O número de condição saltou de 36,2 no Grau 1 para 24.300 no Grau 3 (aumento de quase 1.000 vezes). No padrão IEEE 754 de precisão dupla ($\sim$ 16 dígitos decimais significativos), $\kappa = 2{,}4 \times 10^4$ acarreta a perda de 4 a 5 dígitos decimais por erros de cancelamento catastrófico. Esse resultado comprova experimentalmente o perigo analítico de utilizar matrizes de Vandermonde de ordem elevada na resolução de sistemas lineares.

5 Considerações Finais

O projeto atingiu a totalidade dos requisitos pedagógicos e científicos da Unidade II de Computação Numérica.

Conclui-se que não existe modelo universalmente superior (*No Free Lunch Theorem*):

- Para sistemas físicos determinísticos com acentuada não-linearidade local (como saturação magnética, transientes de tensão ou curvas de potência eólica), a **RBF Gaussiana** é a ferramenta ideal e mandatória, sendo capaz de mapear geometrias que os polinômios não conseguem sem oscilar descontroladamente.

- Para correlações clínicas e epidemiológicas com elevada dispersão estocástica e tendência média monotônica, o **MMQ Linear simples** é insuperável em robustez, simplicidade de implementação e custo computacional.

6 Repositório de Código

Todo o código-fonte desenvolvido segundo as boas práticas de engenharia de software (PEP 8, tipagem estática e testes unitários automatizados) está disponível publicamente em:

`https://github.com/Jacsonrn/ufrn-ect3401-rbf-curve-fitting`

Referências

[1] BISHOP, C. M. *Pattern Recognition and Machine Learning*. New York: Springer, 2006.

[2] HAYKIN, S. *Neural Networks and Learning Machines*. 3ª Edição. New Jersey: Pearson, 2008.

[3] GOLUB, G. H.; VAN LOAN, C. F. *Matrix Computations*. 4ª Edição. Baltimore: Johns Hopkins University Press, 2013.

[4] HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2ª Edição. New York: Springer, 2009.