1 Mini projeto — Regressão via RBF (Gaussianas).

Definição do Problema: aprender a **curva de potência** de uma turbina eólica — potência elétrica (kW) em função da velocidade do vento (m/s) — e utilizá-la para identificar horas em que a turbina produziu menos do que o esperado.

Dados horários reais de uma turbina Fuhrländer FL2500 de 2,5 MW (turbina 80), referentes a 2012, incluindo seu registro de alarmes (fonte: github.com/alecuba16/fuhrlander, EPL-2.0).

1.0.1 Etapas:

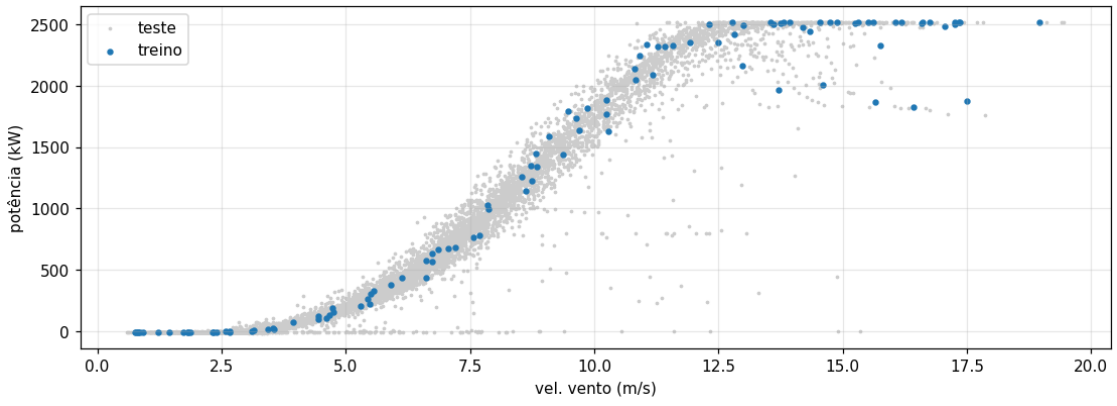
1. Examinar os dados
2. Construir atributos RBF gaussianos com **centros e escolhidos manualmente**
3. Treinar usando a **equação normal**
4. Treinar usando **descida do gradiente** — e verificar se obtemos a mesma resposta
5. Observar o que acontece ao alterar e o número de centros
6. Utilizar o modelo para detectar operação anormal

1.1 1. Dados

Cada linha representa uma hora: velocidade média do vento, potência média e indicação de que um **alarme de parada** do registro da turbina esteve ativo durante aquela hora. Para o treinamento, usamos apenas horas sem alarmes de parada ("operação normal").

Na maioria das horas, os ventos são moderados; ventos fortes são raros. Uma amostragem puramente aleatória deixaria pouquíssimos pontos de treinamento em velocidades elevadas, obrigando o modelo a fazer estimativas nessa região. Por isso, selecionamos uma amostra **estratificada**: 6 horas aleatórias de cada intervalo de velocidade do vento de 1 m/s (110 pontos, fáceis de visualizar em um gráfico). Todos os demais dados compõem o conjunto de teste.

```
8674 horas em 2012, 460 com um alarme de parada | treinamento 109, teste 8105
```



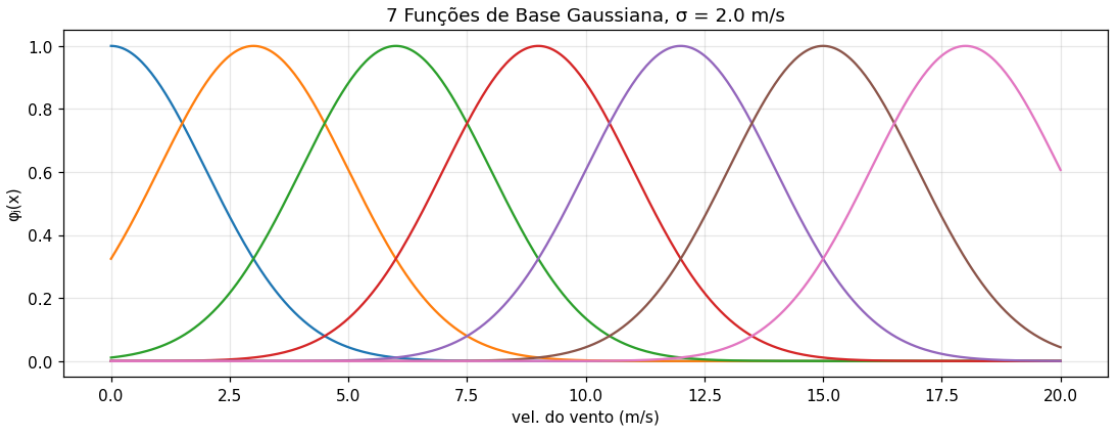
A clássica curva em S: nenhuma produção abaixo de aproximadamente 3 m/s (velocidade de entrada em operação, *cut-in*), um crescimento acentuado (potência v^3) e um patamar na potência nominal de 2500 kW, em que o ajuste do ângulo das pás limita a potência. Uma reta não consegue ajustar essa relação — mas uma soma de funções gaussianas consegue.

1.2 2. O modelo

$$\hat{y}(x) = w_0 + \sum_{j=1}^{M} w_j\,\phi_j(x), \qquad \phi_j(x) = \exp\left(-\frac{(x-c_j)^2}{2\sigma^2}\right)$$

- c_j: **centros** — onde cada função gaussiana está posicionada (escolhidos manualmente)
- σ: **largura** — quão larga é cada função gaussiana (escolhida manualmente)
- w_j: **pesos** — aprendidos a partir dos dados

O modelo é não linear em x, mas **linear em w**. Ao organizar os atributos dos N pontos de treinamento, obtemos a matriz de projeto Φ (dimensão $N \times (M+1)$, primeira coluna $= 1$) e $\hat{\mathbf{y}} = \Phi\mathbf{w}$.



Regra prática para a escolha manual: distribua os centros ao longo do intervalo onde há dados e escolha σ pela ordem do espaçamento entre centros vizinhos, para que as funções gaussianas se sobreponham sem se tornarem praticamente iguais.

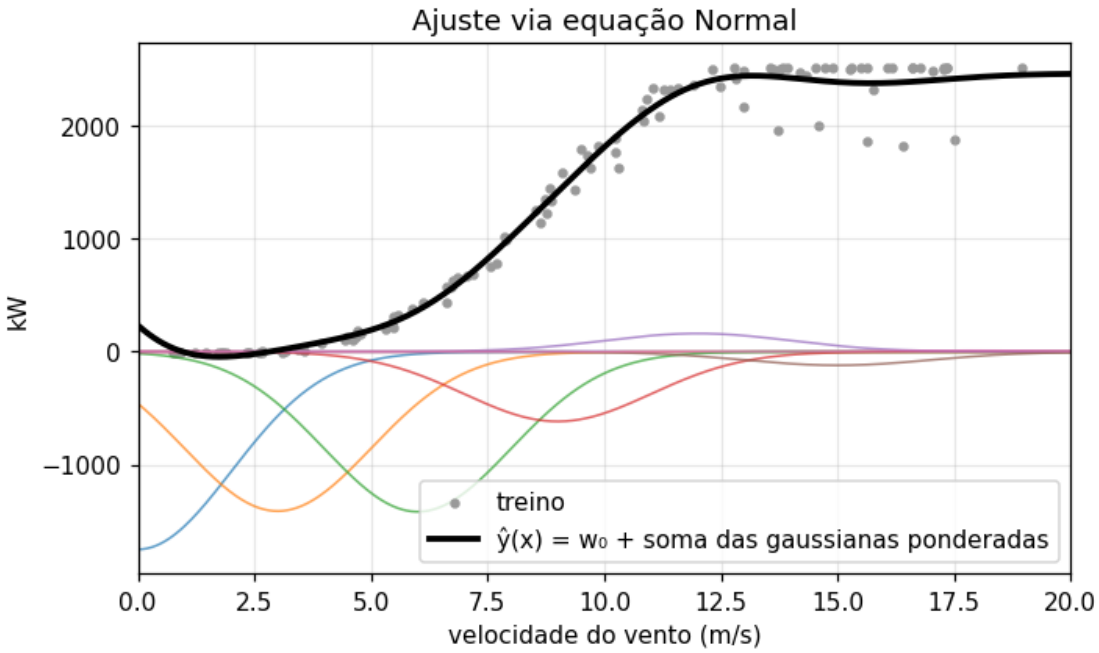
1.3 3. Treinamento com a equação normal

Minimizamos o erro quadrático médio $J(\mathbf{w}) = \frac{1}{N}\|\Phi\mathbf{w} - \mathbf{y}\|^2$. Igualando o gradiente a zero:

$$\nabla J = \frac{2}{N}\Phi^\top(\Phi\mathbf{w} - \mathbf{y}) = 0 \quad \Longrightarrow \quad \boxed{\Phi^\top\Phi\,\mathbf{w} = \Phi^\top\mathbf{y}}$$

Uma única resolução de sistema linear, sem iterações (`np.linalg.pinv`; nunca calcule explicitamente a inversa).

```
pesos: [ 2460.9 -1752.  -1412.3 -1417.8  -617.7   161.8  -120.4    10.6]
treino RMSE = 136 kW,  teste RMSE = 160 kW
```



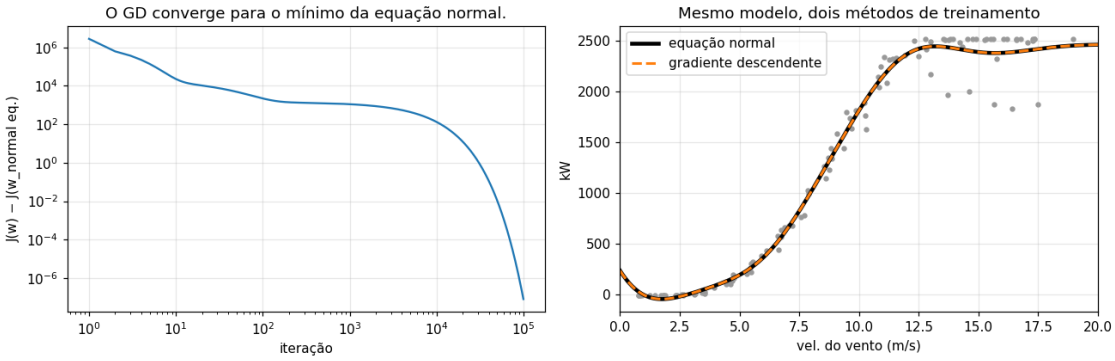
1.4 4. Treinamento com o gradiente descendente

Mesma função custo, mas com solução iterativa:

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \nabla J(\mathbf{w}), \qquad \nabla J = \frac{2}{N}\Phi^\top(\Phi\mathbf{w} - \mathbf{y})$$

Escolha da taxa de aprendizado. A função custo tem a forma de uma superfície quadrática convexa, com Hessiana $H = \frac{2}{N}\Phi^\top\Phi$. A descida do gradiente só converge se $\eta < 2/\lambda_{\max}(H)$; $\eta = 1/\lambda_{\max}$ é uma escolha inicial segura.

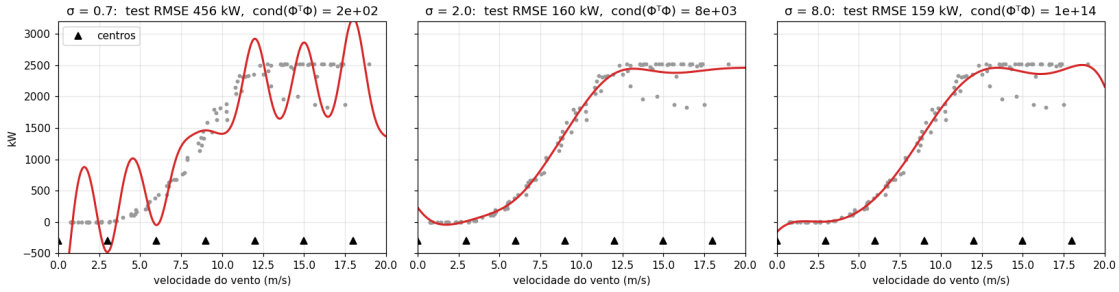
`max = 2.820 → = 0.355 (diverge acima 0.709); condicionamente max/ min = 8488`



```
normal eq.: [ 2460.9 -1752.  -1412.3 -1417.8  -617.7   161.8  -120.4    10.6]
grad. desc: [ 2460.9 -1751.9 -1412.3 -1417.8  -617.7   161.8  -120.4    10.6]
```

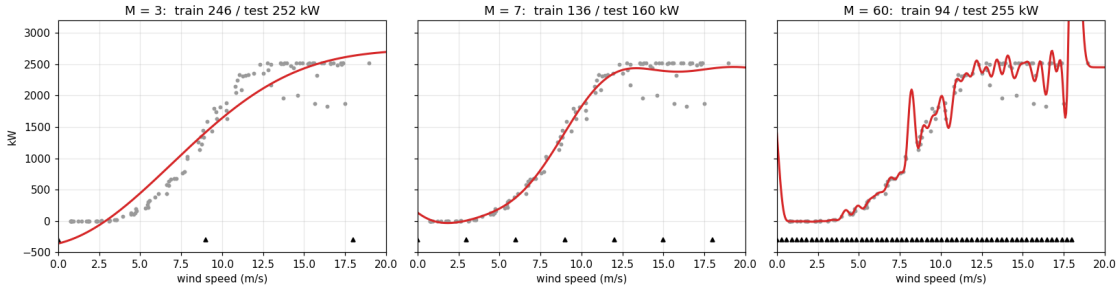
1.5 5. Escolha manual de e dos centros

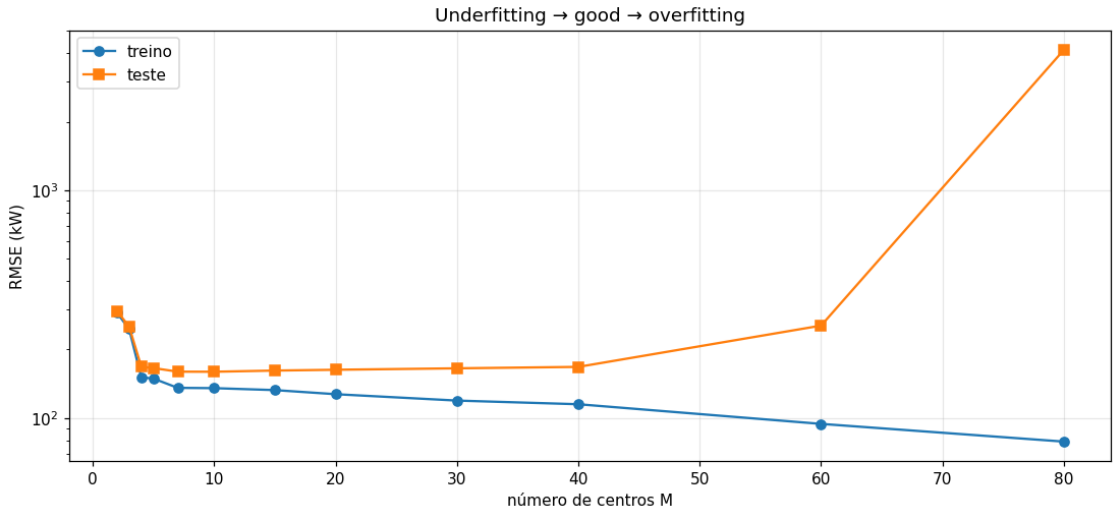
1.5.1 5.1 A largura (os mesmos 7 centros)



- **muito pequeno:** as funções gaussianas não se sobrepõem — a curva apresenta depressões entre os centros.
- **espaçamento:** curva suave que acompanha os dados.
- **muito grande:** todas as funções gaussianas ficam parecidas (as colunas de Φ tornam-se quase idênticas), $\Phi^\top\Phi$ fica quase singular (número de condição enorme), os pesos tornam-se muito grandes e instáveis, e a descida do gradiente seria extremamente lenta.

1.5.2 5.2 O número de centros M (= espaçamento entre centros)



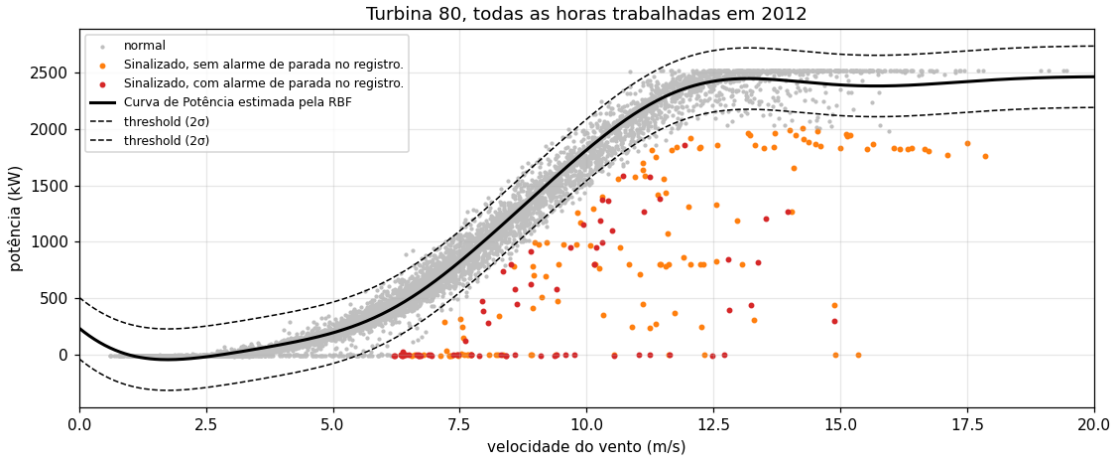


- **Poucos centros:** a curva não consegue se ajustar suficientemente (subajuste, *underfitting*) — erros de treinamento e de teste elevados.
- **Centros demais** para ~110 pontos: a curva passa a acompanhar o ruído e apresenta oscilações extremas onde há poucos dados (ventos fortes) — o erro de treinamento continua diminuindo, mas o erro de teste aumenta (sobreajuste, *overfitting*).
- Escolha o modelo mais simples cujo erro de teste (preferencialmente, de *validação*) esteja próximo do mínimo.

1.6 6. Uso do modelo: detecção de operação anormal

A curva ajustada informa quanta potência a turbina **deveria** produzir para cada velocidade do vento. Agora, aplicamos o modelo a **todas** as horas de 2012, inclusive às que não foram utilizadas anteriormente. O resíduo $r = y - \hat{y}$ é fortemente negativo quando a turbina produz muito menos do que o esperado — por parada, falha ou redução da potência disponível. Regra: sinalizar uma hora quando $r < \pm 2\,\hat{\sigma}_r$ (sendo $\hat{\sigma}_r$ o desvio-padrão dos resíduos nos dados de treinamento) e o vento estiver acima da velocidade de entrada em operação (4 m/s).

```
desvio padrão residual nos dados de treinamento: 136 kW  → threshold -408 kW
horas sinalizadas pelo modelo:          199
  …que contava com um alarme de parada:      70
horas com um alarme de parada (vento > 4):  357  → captado pelo modelo: 20%
```



Interpretação do resultado. * Vermelho: o modelo e o registro de alarmes concordam — a turbina estava parada ou apresentava falha naquela hora. * Laranja: potência muito abaixo da curva **sem** alarme de parada — geralmente paradas durante parte da hora, restrição de geração (*curtailment*) ou redução da potência nominal (*derating*), por exemplo, para atender à rede elétrica ou devido a temperaturas elevadas. São precisamente as horas que um engenheiro de desempenho deve examinar. * Os alarmes de parada não detectados pelo modelo correspondem, em sua maioria, a horas em que a parada durou apenas alguns minutos, de modo que a potência média horária permaneceu próxima do normal.

Um modelo de regressão do comportamento *normal* combinado com um limiar aplicado aos resíduos constitui a ideia central de muitos sistemas de monitoramento de condição.

1.7 Exercícios

1. Posicione os centros de forma **não uniforme**, por exemplo, concentrando mais centros próximo à região de transição da curva (10–13 m/s). É possível obter o mesmo erro de teste com menos centros?
2. Com os 7 centros, represente graficamente o RMSE de teste em função de , de 0,5 a 8. Onde ocorre o mínimo? Compare-o com o espaçamento.
3. Execute a descida do gradiente com = 4. Quantas iterações são necessárias e por quê? (Dica: número de condição.)
4. Adicione uma penalização ridge: $(\Phi^\top\Phi + N\lambda I)\mathbf{w} = \Phi^\top\mathbf{y}$. Use-a para recuperar o modelo com M = 60.
5. Treine usando **todas** as horas normais, em vez de ~110. O modelo com M = 60 ainda apresenta sobreajuste? Por quê?
6. Substitua a amostra estratificada por 110 horas inteiramente aleatórias. O que acontece com a curva acima de 13 m/s e por quê?
7. Altere o limiar de detecção (-2 , -4). Como mudam as quantidades de pontos vermelhos e laranjas?